

Fördjupning Python Rapport

Vera Stopp

Syfte

Projektets syfte är att automatisera hela rapporteringskedjan, från rådata till färdigställd analysrapport.

Område och dess relevans

Projekten kombinerar en Python-pipeline med Quarto och LaTeX för att skapa ett flöde hela vägen från inläsning av rådata till datarensning, visualisering och kompilering av en slutgiltig PDF-rapport.

Inom datadrivna verksamheter växer mängden data snabbt vilket skapar ett behov av att snabbt och tillförlitligt omvandla analysresultat till beslutsunderlag. Manuellt skapade rapporten är tidkrävande och sårbara för mänskliga fel. Genom att automatisera hela flödet sparas tid och säkerställs reproducerbarhet och spårbarhet.

Viktiga begrepp

- Quarto Document (.qmd): Det primära filformatet. En utökad variant av Markdown som gör det möjligt att blanda vanliga textformateringar, LaTeX-ekvationer och kodblock i ett och samma dokument.
- YAML Front Matter: Block som placeras längst upp i .qmd-filen. Här definieras dokumentets inställningar såsom författare, output-format, språk och marginaler.
- Cell Options: Inställningar som skrivs längst upp i ett kodblock med syntaxen `#|`. De styr hur koden och dess resultat presenteras i rapporten.
- Rendering/Kompilering: Processen där Quarto omvandlar .qmd-filen till det slutgiltiga formatet.

Genomförande

Projektet bygger en Python-pipeline som bearbetar inkomstdata från Statistiska centralbyrån (SCB). Rådata läses in i CSV-format och innehåller information om kön, utbildningsnivå, år och medelinkomst.

Följande huvudsakliga verktyg och bibliotek har använts:

- Pandas
- Matplotlib & Seaborn

- Pytest
- Quarto

Projektet är strukturerat som ett installerbart Python-paket (`income_report`) med en tydlig ansvarsfördelning:

1. Datavalidering och laddning (`loading.py` & `validation.py`): Rådata läses in och kontrollerad så att alla nödvändiga kolumner och datatyper finns.
2. Databehandling (`processing.py`): Data rensas, beräkningar genomförs och bearbetade CSV-filer sparas.
3. Visualisering (`visualization.py`): Seaborn/Matplotlib genererar alla diagram och sparar högupplösta bildfiler.
4. Rapportgenerering (`reporting.py`): Quarto anropas och hämtar de fräska CSV-filerna och bilderna. PDF-fil skapas.

Viktiga tekniska val:

- Modulär paketstruktur med `pyproject.toml`
- Standardiserad loggning
- Explicita cell options i Quarto

Där jag fastnade mycket i utformningen var när jag skulle koda testen. Det krävde mycket tid att komma på bra test som testade funktionerna på ett bra sätt. Även vid skrivandet av YAML-header fastnade jag länge. Jag försökte kolla olika videos och läsa på Quartos egna sida men svårt att förstå hur jag skulle göra för att till exempel ändra font i rapporten eller tillverka sidhuvud.

Resultat

Inkomstanalys: Lönestruktur och Utveckling över Tid

En analys baserad på data från Statistiska centralbyrån (SCB)

Vera Stopp

2026-09-24

Innehållsförteckning

1	Introduktion	1
2	Extremvärden och Inkomstklyftor	2
3	Utbildningens Avkastning över Tid	3
4	Köns- och Inkomstutveckling	4
5	Ålders- och livscykelprofil	6


1 Introduktion

Denna rapport sammanställer och analyserar inkomstdata från Statistiska centralbyrån (SCB). Syftet är att undersöka hur medelinkomsten varierar beroende på faktorer som utbildningsnivå, kön och ålder samt hur dessa realtioner har förändrats över tid. Datan sträcker sig från 2010 och 2024.

Data har genomgått en automatiserad validerings- och bearbetningspipeline där saknade värden har rensats och datatypstransformationer genomförts innan aggregering.

2 Extremvärden och Inkomstklyftor

Genom att identifiera den grupp som har högst respektive lägst medelinkomst för varje enskilt år kan vi studera spannet i inkomstfördelningen.




Figur 1: Jämförelse mellan den grupp som uppvisar högst respektive lägst medelinkomst per år.

Som visas i Figur 1 uppgår den högsta noterade medelinkomsten för år 2024 till 735.7 tkr (tillhörande gruppen män med utbildningsnivå eftergymnasial utbildning). Detta kan jämföras med den lägsta medelinkomst på 151.4 tkr, vilket ger en skillnad på 584.3 tkr mellan grupperna.

Mellan år 2010 och 2024 ökade medelinkomsten för gruppen med högst inkomst med 255.5 tkr (en ökning med 53.2 %) medan motsvarande ökning för gruppen med lägst inkomst var 62.6 tkr (70.5 %).

3 Utbildningens Avkastning över Tid

Utbildning ses ofta som en av de mest avgörande faktorerna för individens inkomstutveckling. Figuren 2 illustrerar hur medelinkomsten har utvecklats för olika utbildningsnivåer under den analyserade tidsperioden.



Figur 2: Inkomstutveckling sorterad på utbildningsnivå över tid.

Trenden visar tydligt att högre utbildningsnivåer korrelerar med en högre genomsnittlig inkomst samt att inkomstgapet mellan olika utbildningsnivåer har varit relativt stabilt eller ökande över tid.

Begränsningar och möjliga förbättringar

- Beroende av en strikt filstruktur: pipelinen är hårt kopplad till kolumnnamn och datastrukturen i SCB:s inkomstdata. Om ett kolumnnamn skulle ändras krävs manuella koduppdateringar för att pipelinen inte ska krascha.
- Quarto är begränsat i layout. Upplevde det som svårt att få rapporten att se professionell ut.
- Ett utvecklingsområde hade varit att pipelinen också skulle ha en prognosmodellering för att förutsäga framtida inkomstutveckling.

Koppling till yrkesrollen

En dataanalytiker kan tillämpa detta arbetssätt i flera skeden:

- Återkommande uppföljningar och månadsrapporter
- Effektiv kommunikation till icke-tekniska personer
- Byggnad av skräddarsydda analysverktyg: genom att koden är paketerad som en Python-modul kan den återanvändas i andra projekt.

Källor

Quarto Crash Course: https://youtu.be/_VKxTPWDhA4?si=GFvkkWjA58Ga28R

<https://quarto.org/docs/guide/>

https://data-vis-using-r.info/03_intro_to_quarto/intro_to_quarto.html

Självreflektion

Jag lärde mig att arbeta i Quarto Markdown. Det var också ett bra projekt för repetition av paket, moduler och test i Python. Om jag hade börjat om från början hade jag börjat med att läsa på mer om Quarto och testa det innan jag satte mig med all kodning gällande validering och uträkningar. Den delen tog lång tid och när det var klart hade jag inte mycket tid kvar att fördjupa mig i Quarto.

Om jag hade fortsatt arbetet hade jag velat göra rapporten mer professionell. Jag hade velat djupdyka mer i YAML header och vilka alternativ som finns. Jag hade också velat göra någon form av prognos-uträkning så att programmet skulle kunna förutsäga medelinkomsten för en viss grupp några år framåt.

Jag anser att mitt arbete motsvarar betygsriterierna för Godkänt. Jag har valet ett avgränsat område som är relevant för yrket. Jag har format en tydlig kodstruktur och ett

program som kan köras med ett anrop från terminalen. Har även dokumenterat här i rapporten och i README hur projektet är uppbyggt och hur det ska köras.